

把 Gemma 4 装进一通电话—— 让孤独的那一刻，先被听见。

Lonely FM 是一个面向中文用户的语音陪伴 Web 应用。我们强调使用 **Gemma 4** 的小参数版本（如 gemma4:e4b / gemma4:12b-mlx），让对话核心能在普通笔记本与手机上直接跑起来——把"按下说 → 听到回应"压到接近真实通话的延迟，让孤独时刻的第一句话不必先组织成一段文字。

AI for Good

Gemma 4 · Small-param · On-device

Voice-first

Mandarin Chinese

Privacy by default

为什么必须是 Gemma 4

这不是一个"恰好用了 LLM"的项目。我们专门挑了 Gemma 4 的小参数版本——它让"本地运行的语音陪伴"在普通笔电与手机上都成立，是这套产品形态的承重柱。

SMALL-PARAM · ON-DEVICE

笔电与手机直接跑得动

我们采用 Gemma 4 的小参数版本（如 gemma4:e4b / gemma4:12b-mlx）。它内存与算力门槛低，普通 MacBook、轻薄本、新一代手机都能本地推理——让"陪伴"不必依赖云端，也不必依赖高端硬件。

LATENCY

通话级首字延迟

陪伴的体感不取决于回复多长，而取决于"你刚停下，它就开口"。Gemma 4 小参数版本在 MLX / Ollama 上的首字延迟，足以撑起"通话感"，这是大参数云端模型给不了的本地体验。

PRIVACY

对话不离开你的设备

小参数 + 本地推理 = 敏感的陪伴对话天然留在用户机器上。开源权重让"温暖"和"隐私"第一次可以同时成立，而不是二选一。


MANDARIN

小模型也能接住中文

多数小参数开源模型在中文口语场景上是机械的。Gemma 4 小参数版本对半句话、停顿、语气词、情绪起伏的鲁棒性，让我们敢把"先听完再回应"的人格设定建在它上面。

系统架构

三层：浏览器作为采集与回放、FastAPI 作为编排层、AI 能力以薄服务边界形式接入。Gemma 4 是这套架构的核心，其余服务都围绕它做"让 Gemma 听得见 / 说得出 / 记得住"。



三条 AI 能力，三组双路

每一项能力都有"主路径 + 备选"。主路径决定演示效果，备选决定能不能在评委环境跑起来。Gemma 4 在主路径上承担最重的角色。

LLM · 承重

Gemma 4 小参数 · 端侧优先

主路径

Ollama · gemma4:e4b / gemma4:12b-mlx

笔电、手机本地推理

备选

云端 Gemma 4 API（极低配设备 / 评委无本地模型时）

EMOTION

专业模型 + 启发式兜底

主路径

Hume Expression Measurement（流式）

备选

本地 prosody（电平 / 语速 / 沉默）+ 中文文本启发式

TTS

情绪化语音 + 通用兜底

主路径

MiniMax Speech 2.8（WS 流式 + 情绪标签）

备选

Google Cloud TTS · Chirp3-HD

一次完整对话的端到端数据流

双路径回复策略：第一句走低延迟"兜底"，立刻播放给用户「我在听」；后续 chunk 走流式，并行追加文本与音频。这是把 Gemma 4 用出"通话感"的关键。

用户按住说话 → 浏览器录音 + 实时 STT

▼ ws.send { audio_chunk | user_text | prosody }

Backend WebSocket

- ① turn 检测 (静默 $\geq 900\text{ms}$ 或句末标点)
- ② 情绪 = `hume.analyze()` 或 `local_prosody.analyze()`
- ③ 取 session 历史 + Supabase 记忆
- ④ `persona.build_prompt()`(情绪 + 韵律 + 记忆 + 人格)
- ⑤ `gemma.stream()` — Gemma 4 边生成边切句
 - 第一句: FAST PATH (确认"我在听", 最低延迟)
 - 后续: STREAMING PATH (并行追加)
- ⑥ 每一句送 `tts.py` (情绪 → 语速 / 音高 / 呼吸 / 停顿)
- ⑦ WebSocket 下推: `ai_text_chunk + audio_chunk + emotion`

Frontend useWebSocket:

- 打字机文本 (`useTypewriter`)
- 音频增量播放 (`StreamingAudioHandle`)
- 缓存音频供"重放"
- `memory_sync` 实时同步记忆

延迟难题：从"按下说"到"听到回应"

语音陪伴最难做的不是模型说了什么，而是"你刚停下，它就开口"。我们用六个动作把端到端延迟压到通话级，每一条都对应了 routers / services 里可被指认的代码段。

① 小参数 LLM

把首字延迟交给端侧

Gemma 4 小参数版本 (e4b / 12b-mlx) 让首字在普通笔电上几百毫秒就能出来——大参数云端模型的"等几秒"在陪伴语境里是不可接受的。

② PREWARM

消除冷启动

后端启动时后台预热 Gemma 4 与常用 TTS 短句 ("我在""慢慢说""我听见了")。第一通电话不再承担 ~5s 的模型加载与首句合成。

③ FAST-PATH + STREAMING

第一句兜底，后续流式

识别到 turn 结束的瞬间，先回一句极短的承接 ("这句我听懂了")，用预合成音频立刻播放；同时 Gemma 4 在后台并行生成完整回复，边生成边切句送 TTS。

④ STREAMING TTS

边合成边播放

MiniMax Speech 2.8 走 WebSocket，音频以 chunk 的形式实时返回。用户听到第一个字时，整句话还没合成完——TTS 不再是"等完整段落再说"。

⑤ BROWSER STT

识别在本地，不绕服务器

Web Speech API 让识别文字在浏览器内直接产生，无需"录完→上传→转写"三段往返。WebSocket 上传送的是 prosody + 已有的文本，而不是等待 transcribe 的音频块。

⑥ 激进 TURN 检测

900ms 静默即认作一轮

客户端 VAD + 句末标点双判：静默 $\geq 900\text{ms}$ 或听到完整句号即触发回复，不等用户"说完整段落"。配合 prosody 标记延续语，避免误切短停顿。

关键工程决策

这些不是 LLM 调用层面的事，是把"语音陪伴"做出体感的产品工程动作。

01 Prewarm 消除冷启动

后端启动时后台预热 Gemma 4 与常用 TTS 短句（"我在""慢慢说"），让第一次对话不用承担 ~5s 的模型加载。

02 Prosody-aware Prompt

把用户的平均音量、语速、尾部静默、字符率一起喂给 Gemma 4，让 Gemma 的回复匹配"说话状态"，而不仅是文字内容。

03 情境化情绪传递

当前回合情绪信号弱时，沿用前几回合的情绪基调（softened），避免声音在 calm ↔ sad 之间反复横跳。

04 危机响应分支

识别到高风险表达直接切到安全应答路径，附 12356 心理援助热线引导，不进入普通陪伴流程。

05 记忆按账号隔离

Postgres + RLS（行级安全）。访客模式不写入；登录用户的记忆只服务自己的下一次对话，且可手动删除。

06 Demo Fallback

缺 API key 或缺本地模型时也能跑通核心 WebSocket 流程，确保评委网络环境下不会"黑屏"。

完整技术栈

选型偏好：成熟、可演示稳定、可替换。每一层都保留 fallback。

FRONTEND

React 18 · TypeScript · Vite · Tailwind v3 · Zustand · React Router

麦克风 + Web Speech API 实时 STT；WebAudio 做电平 / VAD；单一 WebSocket 收发流式文本与音频。

BACKEND

Python 3.11 · FastAPI · Uvicorn · WebSocket · httpx

分层：routers / services / models / prompt。启动时后台 prewarm 模型与短句 TTS。

LLM

Gemma 4 小参数版本 · Ollama (gemma4:e4b / gemma4:12b-mlx) / Cloud Gemma API 兜底

小参数让笔电与手机直接跑通本地推理；OpenAI 兼容 / Ollama 双协议适配，同一 prompt 路径切换。

EMOTION

Hume Expression Measurement / local-prosody 启发式

服务边界薄，可平滑替换为 Hume EVI / 本地 wav2vec / openSMILE。

TTS

MiniMax Speech 2.8（WS 流式 + 情绪化标签） / Google Cloud TTS (Chirp3-HD)

情绪状态 → 语速 / 音高 / 呼吸 / 停顿映射。

DATA / AUTH

Supabase Auth · Postgres · RLS

memories 表按 user_id 隔离；访客不写入；可删除。

DEPLOY

Vercel（前端）+ 独立 FastAPI 后端

演示机本地：Ollama + OLLAMA_ORIGINS 放行域，HTTPS 直连本地 Gemma 4。

边界与安全

我们做的是「陪伴」，不是「咨询」。这条线在产品文案、prompt 和代码里同时存在。

IN PRODUCT COPY

不替代医疗，也不制造依赖

背景页与团队页明确写出：访客离开即不留痕，登录后的记忆由你决定保留或删除。Lonely FM 是一个能被关掉的电台，不是一个让人放不下的应用。

IN PROMPT

人格设定先听完，再回应

prompt/persona.py 把"先承认情绪、再问一个小问题、不急着给建议"作为基础约束注入 Gemma 4 的每一轮对话。

IN CODE

危机响应直接走安全路径

识别到高风险表达（如自伤）时，routers/ws.py 不再走普通生成，而是返回 CRISIS_SAFETY_REPLY，附 12356 心理援助热线，并建议联系信任的人。

IN DATA

隐私默认开

本地 Gemma 4 路径下，对话不离开用户机器；记忆走 Supabase 行级安全，按 user_id 隔离；访客模式不写入持久存储。

评委演示路径

提交版默认演示流程，60 秒内可走完。

01 打开 Web 应用

访问 Vercel 部署的前端站点。

02 登录或访客进入

支持邮箱登录（Supabase Auth）或访客模式（不持久化）。

03 /setup 自检

前端自动探测评委电脑上的 Ollama 与 Gemma 4 模型；无本地模型时切到云端 API key 模式。

04 选择声线

"林屿"（深夜电台 / 安静、克制）或"阿婉"（温柔陪伴 / 轻松、治愈）。

05 开口说话

按住说一句中文，例如"今天好累"。立即听到 AI 的第一句兜底回复，随后是流式后续。

06 查看记忆

登录用户的关键句会被保存为可删除的记忆，下一次对话自动注入 prompt。

Beyond MVP · 我们已经规划的下一步

这部分不在本次提交评分范围内，但我们想让评委看到：我们没有把它当一次性 demo。

MULTIMODAL

Gemma 多模态开场

用户可选上传"今晚的桌面 / 一张照片 / 一段便签照片"，Gemma 看完后说出第一句话——让对话从一个具体场景开始，而不是空白。

LONG CONTEXT

夜聊回看

用 Gemma 4 的长上下文做"完整夜聊回看"——把过去几次对话一次性塞进 prompt，避免对老用户每次都从陌生开始。

TUNING

中文情绪场景 LoRA

用人工标注的中文情绪对话样本，对 Gemma 4 做轻量 LoRA，让"先承认情绪、再问小问题"的人格更稳定。

EVAL

量化首字延迟与情绪命中率

把端到端首字延迟、情绪识别命中率、回复匹配度做成可重复的 eval pipeline，作为持续迭代的基线。

团队

两个人，把孤独时刻做成一通可接起的声音。

JOHNNY WANG

产品方向 / 体验设计 / 演示叙事

把 Lonely FM 的定位、交互、视觉和评审表达串起来，让它不是一个临时 Demo，而是一个能被理解、能被试用、也能被记住的 AI for Good 产品。

TIM TSUI

技术协作 / 模型验证 / 本地部署

协作验证 Gemma 4、本地 Ollama 使用路径和真实测试流程，确保队友、评委和不同设备上的体验尽可能稳定、清楚、可复现。

**用 Gemma 4 做
一通能被接起的电话。**

LONELY FM · SUBMISSION